

分类号: U491

单位代码: 10618

密 级:

学 号: 2021xxxxxx



重庆交通大学
CHONGQING JIAOTONG UNIVERSITY

博 士 学 位 论 文

论文题目（一号宋体）

研 究 生 姓 名: (小三号黑体)

导师姓名及职称: (小三号黑体)

申请学位类别: 博士学位

学位授予单位: 重庆交通大学

一级学科名称: 交通运输工程

论文提交日期: 2024 年 5 月 10 日

二级学科名称: 交通信息工程及控制

论文答辩日期: 2024 年 5 月 15 日

2024 年 6 月

重庆交通大学学位论文原创性声明

本人郑重声明：所呈交的学位论文，是本人在导师的指导下，独立进行研究工作所取得的成果。除文中已经注明引用的内容外，本论文不包含任何其他个人或集体已经发表或撰写过的作品成果。对本文的研究做出重要贡献的个人和集体，均已在文中以明确方式标明。本人完全意识到本声明的法律结果由本人承担。

学位论文作者签名：_____ 日期：____年__月__日

重庆交通大学学位论文授权使用授权书

本学位论文作者完全了解学校有关保留、使用学位论文的规定，同意学校保留并向国家有关部门或机构送交论文的复印件和电子版，允许论文被查阅和借阅。本人授权重庆交通大学可以将本学位论文的全部内容编入有关数据库进行检索，可以采用影印、缩印或扫描等复制手段保存和汇编本学位论文。同时授权中国科学技术信息研究所将本学位论文收录到《中国学位论文全文数据库》，并进行信息服务（包括但不限于汇编、复制、发行、信息网络传播等），同时本人保留在其他媒体发表论文的权利。

学位论文作者签名：_____ 指导教师签名：_____

日 期：____年__月__日 日 期：____年__月__日

本人同意将本学位论文提交至中国学术期刊（光盘版）电子杂志社 CNKI 系列数据库中全文发布，并按《中国优秀博硕士学位论文全文数据库出版章程》规定享受相关权益。

学位论文作者签名：_____ 指导教师签名：_____

日 期：____年__月__日 日 期：____年__月__日

摘 要

本文针对智能交通系统优化问题，提出了一种基于深度学习的交通流量预测与优化方法。通过构建多层神经网络模型，实现了对城市道路网络交通流量的准确预测，并结合强化学习算法优化信号灯控制策略。

研究首先收集了重庆市主城区典型路段的交通流量数据，建立了包含时空特征的交通数据集。在此基础上，设计了融合卷积神经网络（CNN）和长短期记忆网络（LSTM）的混合深度学习模型，用于捕捉交通流的时空演化规律。实验结果表明，该模型在短期交通流预测任务中的平均绝对误差（MAE）降低了 23.5%，均方根误差（RMSE）降低了 18.7%。

进一步，本文将交通信号控制问题建模为马尔可夫决策过程（MDP），采用深度 Q 网络（DQN）算法学习最优控制策略。仿真实验显示，与传统固定配时方案相比，基于 DQN 的自适应信号控制使平均车辆延误时间减少了 31.2%，路网通行能力提升 24.6%。

本研究为智能交通系统的优化提供了新的技术路径，具有重要的理论意义和应用价值。

关键词：智能交通系统；深度学习；交通流量预测；信号灯优化；强化学习

ABSTRACT

This thesis addresses the optimization problem of intelligent transportation systems by proposing a deep learning-based traffic flow prediction and optimization method. Through the construction of a multi-layer neural network model, accurate prediction of traffic flow in urban road networks is achieved, and reinforcement learning algorithms are combined to optimize traffic signal control strategies.

The research first collected traffic flow data from typical road sections in the main urban area of Chongqing and established a traffic dataset containing spatiotemporal features. On this basis, a hybrid deep learning model integrating Convolutional Neural Networks (CNN) and Long Short-Term Memory networks (LSTM) was designed to capture the spatiotemporal evolution patterns of traffic flow. Experimental results show that the model reduces the Mean Absolute Error (MAE) by 23.5% and the Root Mean Square Error (RMSE) by 18.7% in short-term traffic flow prediction tasks.

Furthermore, this thesis models the traffic signal control problem as a Markov Decision Process (MDP) and employs the Deep Q-Network (DQN) algorithm to learn optimal control strategies. Simulation experiments demonstrate that compared to traditional fixed-time schemes, DQN-based adaptive signal control reduces average vehicle delay by 31.2% and increases network capacity by 24.6%.

This research provides a new technical approach for the optimization of intelligent transportation systems, with significant theoretical and practical value.

KEY WORDS: Intelligent Transportation System; Deep Learning; Traffic Flow Prediction; Signal Optimization; Reinforcement Learning

目 录

摘要	i
Abstract	ii
第 1 章 绪论	1
1.1 研究背景与意义	1
1.1.1 智能交通系统发展现状	1
1.1.2 深度学习在交通领域的应用	1
1.2 国内外研究现状	1
1.2.1 交通流预测研究现状	1
1.2.2 交通信号控制研究现状	2
1.3 论文主要研究内容	2
1.4 论文组织结构	2
第 2 章 相关理论基础	3
2.1 深度学习基本原理	3
2.1.1 神经网络基本结构	3
2.1.2 反向传播算法	3
2.2 卷积神经网络	4
2.2.1 卷积操作	4
2.2.2 池化操作	4
2.3 循环神经网络	4
2.3.1 RNN 基本结构	5
2.3.2 LSTM 网络	5
2.4 强化学习基本原理	5
2.4.1 马尔可夫决策过程	6
2.4.2 Q 学习算法	6
2.4.3 深度 Q 网络	6
2.5 本章小结	7
第 3 章 总结与展望	8
3.1 全文总结	8

3.2 主要贡献	8
3.3 研究展望	9
3.4 结束语	9
致谢	10
实验数据统计表.....	11
附录.5 交通流量数据集统计	11
附录.6 模型参数配置	11
部分实验结果图表	13
附录.7 训练过程可视化	13
附录.8 预测结果对比	13

第1章 绪论

1.1 研究背景与意义

随着城市化进程的加速，交通拥堵已成为制约城市可持续发展的重要瓶颈。据统计，我国大中型城市高峰时段平均车速已降至 20km/h 以下，交通拥堵造成的经济损失每年超过数千亿元。智能交通系统（Intelligent Transportation System, ITS）作为解决交通问题的重要手段，受到了学术界和工业界的广泛关注^[2]。

1.1.1 智能交通系统发展现状

智能交通系统是将先进的信息技术、数据通信传输技术、电子传感技术、控制技术及计算机技术等有效地集成运用于整个地面交通管理系统而建立的一种在大范围内、全方位发挥作用的实时、准确、高效的综合交通运输管理系统。

当前，智能交通系统主要包括以下几个方面：

1. **交通信息采集系统**：通过各类传感器实时采集道路交通信息
2. **交通信号控制系统**：根据实时交通状况优化信号灯配时
3. **交通诱导系统**：为出行者提供实时路况和最优路径建议
4. **公共交通管理系统**：提高公共交通服务质量和运营效率

1.1.2 深度学习在交通领域的应用

近年来，深度学习技术在计算机视觉、自然语言处理等领域取得了突破性进展，也逐渐被应用于交通领域。深度学习具有强大的特征学习和模式识别能力，能够从海量交通数据中自动提取有效特征，为交通流预测、交通状态识别、交通事件检测等任务提供了新的解决思路。

1.2 国内外研究现状

1.2.1 交通流预测研究现状

交通流预测是智能交通系统的核心问题之一。传统方法主要包括：

- **统计模型**：如 ARIMA 模型、卡尔曼滤波等
- **机器学习方法**：如支持向量机（SVM）、K 近邻（KNN）等
- **深度学习方法**：如循环神经网络（RNN）、长短期记忆网络（LSTM）等

表 1-1 不同交通流预测方法对比

方法类别	代表方法	预测精度	计算复杂度
统计模型	ARIMA	中等	低
机器学习	SVM	较高	中等
深度学习	LSTM	高	高

1.2.2 交通信号控制研究现状

交通信号控制是缓解交通拥堵的重要手段。当前主要的控制策略包括：

1. **固定配时控制**：根据历史数据设定固定的信号配时方案

2. **感应控制**：根据实时检测到的车辆信息调整配时
3. **自适应控制**：利用优化算法动态调整信号配时
4. **智能控制**：基于人工智能技术的自主学习控制

1.3 论文主要研究内容

本文的主要研究内容包括：

1. 构建融合时空特征的交通流预测模型
2. 设计基于深度强化学习的自适应信号控制算法
3. 搭建仿真平台验证所提方法的有效性
4. 分析不同场景下的优化效果和鲁棒性

1.4 论文组织结构

本文共分为六章，各章节内容安排如下：

- 第1章为绪论，介绍研究背景、意义和国内外研究现状。
- 第2章为相关理论基础，介绍深度学习和强化学习的基本原理。
- 第3章为交通流预测模型设计，详细阐述模型结构和训练方法。
- 第4章为交通信号控制算法设计，提出基于 DQN 的自适应控制策略。
- 第5章为实验与分析，验证所提方法的有效性。
- 第6章为总结与展望，总结全文工作并展望未来研究方向。

第2章 相关理论基础

2.1 深度学习基本原理

深度学习是机器学习的一个分支，通过构建多层神经网络来学习数据的层次化表示。与传统机器学习方法相比，深度学习能够自动从原始数据中提取特征，无需人工设计特征工程。

2.1.1 神经网络基本结构

人工神经网络（Artificial Neural Network, ANN）是深度学习的基础。一个典型的神经网络由输入层、隐藏层和输出层组成。神经元之间通过权重连接，并通过激活函数引入非线性。

神经元的输出可以表示为：

$$y = f\left(\sum_{i=1}^n w_i x_i + b\right) \quad (2-1)$$

其中， x_i 为输入， w_i 为权重， b 为偏置， $f(\cdot)$ 为激活函数。

常用的激活函数包括：

Sigmoid 函数：

$$\sigma(x) = \frac{1}{1 + e^{-x}} \quad (2-2)$$

ReLU 函数：

$$\text{ReLU}(x) = \max(0, x) \quad (2-3)$$

Tanh 函数：

$$\tanh(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}} \quad (2-4)$$

2.1.2 反向传播算法

反向传播（Backpropagation, BP）算法是训练神经网络的核心算法。其基本思想是通过梯度下降法最小化损失函数。

损失函数定义为：

$$L(\theta) = \frac{1}{N} \sum_{i=1}^N \ell(y_i, \hat{y}_i) \quad (2-5)$$

其中， θ 表示网络参数， y_i 为真实值， \hat{y}_i 为预测值， $\ell(\cdot)$ 为损失函数。

参数更新规则为：

$$\theta_{t+1} = \theta_t - \eta \nabla_{\theta} L(\theta_t) \quad (2-6)$$

其中， η 为学习率， $\nabla_{\theta} L$ 为损失函数对参数的梯度。

2.2 卷积神经网络

卷积神经网络（Convolutional Neural Network, CNN）特别适合处理具有网格结构的数据，如图像、时间序列等。CNN 通过卷积操作提取局部特征，通过池化操作降低维度。

2.2.1 卷积操作

二维卷积操作可以表示为：

$$(f * g)(i, j) = \sum_m \sum_n f(m, n) \cdot g(i - m, j - n) \quad (2-7)$$

在 CNN 中，卷积层的输出为：

$$y_{ij} = \sigma \left(\sum_m \sum_n w_{mn} \cdot x_{(i+m)(j+n)} + b \right) \quad (2-8)$$

2.2.2 池化操作

池化操作用于降低特征图的空间维度，常用的池化方式包括：

最大池化：

$$y_{ij} = \max_{(m,n) \in R_{ij}} x_{mn} \quad (2-9)$$

平均池化：

$$y_{ij} = \frac{1}{|R_{ij}|} \sum_{(m,n) \in R_{ij}} x_{mn} \quad (2-10)$$

2.3 循环神经网络

循环神经网络（Recurrent Neural Network, RNN）是处理序列数据的重要模型。RNN 通过引入循环连接，使网络具有记忆功能。

2.3.1 RNN 基本结构

RNN 的隐藏状态更新公式为：

$$h_t = \tanh(W_h h_{t-1} + W_x x_t + b) \quad (2-11)$$

输出计算公式为：

$$y_t = W_y h_t + b_y \quad (2-12)$$

2.3.2 LSTM 网络

长短期记忆网络（Long Short-Term Memory, LSTM）通过引入门控机制解决了 RNN 的梯度消失问题。LSTM 包含三个门：遗忘门、输入门和输出门。

遗忘门：

$$f_t = \sigma(W_f \cdot [h_{t-1}, x_t] + b_f) \quad (2-13)$$

输入门：

$$i_t = \sigma(W_i \cdot [h_{t-1}, x_t] + b_i) \quad (2-14)$$

候选细胞状态：

$$\tilde{C}_t = \tanh(W_C \cdot [h_{t-1}, x_t] + b_C) \quad (2-15)$$

细胞状态更新：

$$C_t = f_t \odot C_{t-1} + i_t \odot \tilde{C}_t \quad (2-16)$$

输出门:

$$o_t = \sigma(W_o \cdot [h_{t-1}, x_t] + b_o) \quad (2-17)$$

隐藏状态:

$$h_t = o_t \odot \tanh(C_t) \quad (2-18)$$

2.4 强化学习基本原理

强化学习 (Reinforcement Learning, RL) 是机器学习的另一个重要分支, 通过与环境交互学习最优策略。

2.4.1 马尔可夫决策过程

强化学习问题通常建模为马尔可夫决策过程 (Markov Decision Process, MDP), 定义为一个五元组:

$$\text{MDP} = (S, A, P, R, \gamma) \quad (2-19)$$

其中:

- S : 状态空间
- A : 动作空间
- P : 状态转移概率
- R : 奖励函数
- γ : 折扣因子

2.4.2 Q 学习算法

Q 学习是一种无模型的强化学习算法, 通过学习状态-动作价值函数 $Q(s, a)$ 来获得最优策略。

Q 值更新公式为:

$$Q(s_t, a_t) \leftarrow Q(s_t, a_t) + \alpha \left[r_t + \gamma \max_{a'} Q(s_{t+1}, a') - Q(s_t, a_t) \right] \quad (2-20)$$

其中 α 为学习率。

2.4.3 深度 Q 网络

深度 Q 网络 (Deep Q-Network, DQN) 将深度学习与 Q 学习结合, 使用神经网络近似 Q 函数:

$$Q(s, a; \theta) \approx Q^*(s, a) \quad (2-21)$$

DQN 的损失函数为:

$$L(\theta) = \mathbb{E} \left[\left(r + \gamma \max_{a'} Q(s', a'; \theta^-) - Q(s, a; \theta) \right)^2 \right] \quad (2-22)$$

其中 θ^- 为目标网络参数。

2.5 本章小结

本章介绍了深度学习和强化学习的基本理论，包括神经网络、CNN、LSTM 和 DQN 等模型的基本原理和数学表达。这些理论为后续章节的模型设计和算法实现提供了理论基础。

第3章 总结与展望

3.1 全文总结

本文针对智能交通系统优化问题，开展了基于深度学习的交通流量预测与信号灯控制研究，主要工作和创新点总结如下：

1. 提出了融合时空特征的交通流预测模型

针对交通流的时空相关性，设计了 CNN-LSTM 混合神经网络模型。该模型利用 CNN 提取空间特征，利用 LSTM 捕捉时间依赖关系，有效提升了预测精度。实验表明，相比传统方法，所提模型的 MAE 降低了 23.5%，RMSE 降低了 18.7%。

2. 设计了基于深度强化学习的自适应信号控制算法

将交通信号控制问题建模为 MDP，采用 DQN 算法学习最优控制策略。通过设计状态空间、动作空间和奖励函数，使智能体能够根据实时交通状态自主决策最优信号配时方案。仿真结果显示，与固定配时相比，平均车辆延误减少 31.2%。

3. 构建了完整的仿真验证平台

基于 SUMO 交通仿真软件，构建了包含多个交叉口的城市道路网络仿真环境。开发了模型训练、评估和可视化工具，为算法性能分析提供了有效支撑。

4. 进行了全面的实验验证和分析

系统评估了所提方法在不同交通场景下的性能表现，分析了关键参数对系统性能的影响，验证了方法的有效性和鲁棒性。

3.2 主要贡献

本文的主要贡献包括：

- 理论层面：提出了 CNN-LSTM 混合网络架构用于交通流预测，丰富了深度学习在交通领域的应用理论
- 方法层面：设计了基于 DQN 的自适应信号控制算法，为解决交通信号优化问题提供了新思路
- 实践层面：构建了完整的仿真验证平台，为后续研究提供了工具和数据支持

3.3 研究展望

尽管本文取得了一定的研究成果，但仍存在一些不足，未来可以从以下几个方面继续深入研究：

1. 多模态数据融合

当前模型主要基于交通流量数据，未来可以融合天气、事件、路况等多源异构数据，进一步提升预测精度和控制效果。

2. 大规模路网优化

本文主要针对单个或少数交叉口进行优化，未来可以研究大规模路网的协同优化问题，考虑路网整体性能。

3. 实际场景验证

当前研究主要基于仿真实验,未来需要在真实交通场景中进行验证和优化,解决实际应用中的工程问题。

4. **可解释性研究**

深度学习模型的黑盒特性限制了其在安全关键场景中的应用,未来需要加强模型可解释性研究,提高决策透明度。

5. **隐私保护**

交通数据涉及个人隐私和敏感信息,未来需要研究隐私保护机制,在保证系统性能的同时保护用户隐私。

3.4 结束语

智能交通系统是解决城市交通问题的重要途径,深度学习技术为智能交通系统带来了新的发展机遇。本文的研究工作为交通流预测和信号控制提供了新的技术方案,但仍有许多问题有待进一步探索。相信随着人工智能技术的不断发展,智能交通系统将更加智能化、高效化,为构建智慧城市做出更大贡献。

致 谢

时光荏苒，转眼间三年的研究生学习生活即将结束。回首这段难忘的求学历程，我收获的不仅是学术上的成长，更是人生阅历的积累和思想境界的提升。在论文即将完成之际，我衷心感谢所有给予我帮助和支持的老师、同学和亲友。

首先，我要衷心感谢我的导师 XXX 教授。从论文选题到研究方案设计，从实验实施到论文撰写，导师都给予了悉心指导和大力支持。导师严谨的治学态度、敏锐的学术洞察力和无私的奉献精神深深感染了我，让我受益终生。在我遇到困难时，导师总是耐心倾听、细心分析，帮助我找到解决问题的方法。导师不仅在学术上给予我指导，更在为人处世方面为我树立了榜样。

感谢课题组的 XXX 老师、XXX 老师在研究过程中给予的指导和帮助。感谢师兄师姐们在学习和生活上的关心和帮助，与你们的交流讨论让我开阔了视野，深化了对问题的理解。感谢同届的师弟师妹们，我们一起学习、一起探讨、一起成长，度过了充实而愉快的研究生时光。

感谢学院的各位老师们在课程学习、资格考试、开题报告、中期检查等各个环节给予的指导和帮助。感谢学院行政人员在学习和生活中提供的便利和支持。

感谢国家自然科学基金项目“XXXXXXX”（项目编号：XXXXXXX）的资助，为本研究提供了经费支持。

最后，我要感谢我的父母和家人。是你们的无私付出和默默支持，让我能够安心完成学业。你们的理解、鼓励和期待是我不断前进的动力源泉。

在此，我向所有关心、支持和帮助过我的人表示最诚挚的谢意！

作者：XXX

时间：2024 年 5 月

实验数据统计表

本附录给出了实验中使用的主要数据集统计信息。

附录.5 交通流量数据集统计

表 0-1 交通流量数据集基本信息

数据集	采集地点	时间跨度	数据量	采样间隔
Dataset-1	观音桥路口	2023.01-2023.06	26,280 条	5 分钟
Dataset-2	解放碑路口	2023.01-2023.06	26,280 条	5 分钟
Dataset-3	沙坪坝路口	2023.01-2023.06	26,280 条	5 分钟

附录.6 模型参数配置

表 0-2 CNN-LSTM 模型参数设置

参数名称	参数值
CNN 卷积核大小	3×3
CNN 卷积核数量	64
LSTM 隐藏层单元数	128
学习率	0.001
批量大小	32
训练轮数	100
优化器	Adam

表 0-3 DQN 算法参数设置

参数名称	参数值
状态空间维度	12
动作空间维度	8
经验回放缓冲区大小	10,000
目标网络更新频率	100
折扣因子 γ	0.99
探索率 ϵ	0.1
学习率	0.0001

部分实验结果图表

附录.7 训练过程可视化

本节展示了模型训练过程中损失函数和评价指标的变化曲线。

附录.8 预测结果对比